МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования

«Пензенский государственный технологический университет»

(ПензГТУ)

Факультет автоматизированных информационных технологий

Кафедра «Программирование»

Дисциплина «Прикладные задачи искусственного интеллекта»

Отчет по лабораторной работе №1

«Прикладная задача на табличных данных»

Выполнил:

Студент гр. 23ИВ1б

Клонин Н.М.

Проверил:

к.т.н., доцент кафедры

«Программирование» Маркин Е.И.

г. Пенза, 2026.

1. Цель и задачи работы

Цель работы — пройти полный цикл решения прикладной задачи на табличных данных: от бизнес-постановки до интерпретируемой модели с выбранным порогом решения, которая в лабораторной работе № 2 будет выведена в эксплуатацию.

Вариант 6. Риск отчисления студентов. Набор данных Predict Students' Dropout and Academic Success (UCI, id = 697), 4424 студента, целевая переменная Target с тремя классами (Dropout, Enrolled, Graduate), основная метрика — Macro-F1.

Задачи работы:

– перевести бизнес-задачу в ML-постановку и выбрать метрики;

– провести разведочный анализ данных и найти утечки целевой переменной;

– построить воспроизводимый пайплайн подготовки признаков;

– обучить и настроить модели градиентного бустинга (LightGBM, CatBoost);

– оценить качество с доверительным интервалом по стратифицированной 5-fold схеме и отложенной выборке;

– выбрать порог решения по стоимости ошибок;

– объяснить модель с помощью SHAP и сформулировать выводы для заказчика.

Код выполнен в Google Colab (Python 3, CPU), ноутбук lab1_Klonin.ipynb выполняется сверху вниз после перезапуска среды. Использованы библиотеки pandas, numpy, scikit-learn 1.9, lightgbm 4.7, catboost 1.2, optuna 5.0, shap 0.54, ucimlrepo. Случайное зерно RANDOM_STATE = 42.

2. Постановка задачи

Университет теряет студентов, а вместе с ними — бюджетное финансирование и показатели аккредитации. Учебный офис может направить студента к куратору: консультация, помощь с задолженностями, перевод на другую форму обучения. Консультация недорога, но ресурсы кураторов ограничены, поэтому направлять всех подряд нецелесообразно.

Таблица 1 — Постановка задачи (вариант 6)

Элемент постановки	**Значение**
Проблема	Отчисление студентов: потеря финансирования, ухудшение показателей вуза

Элемент постановки	Значение
Решение и исполнитель	Учебный офис направляет студента группы риска к куратору
Момент прогноза	Сценарий A — зачисление; сценарий B — окончание 1-го семестра (основной)
Объект	Один студент (одна строка набора)
Целевая переменная и горизонт	Target на момент окончания нормативного срока обучения: Dropout — отчислен, Enrolled — продолжает обучение, Graduate — выпустился
Признаки	A: анкета, предыдущее образование, семья, социальные признаки, макроэкономика года поступления; B: дополнительно успеваемость 1-го семестра и состояние оплаты
Метрики	Macro-F1 по трём классам (основная); ROC-AUC и Brier score для вероятности Dropout; суммарная стоимость ошибок (бизнес-метрика)
Цена ошибок	Пропуск будущего отчисленного C_FN = 10 усл. ед.; лишняя консультация C_FP = 1 усл. ед.
Ограничения	Решение объясняется куратору и студенту; нельзя дискриминировать по полу, возрасту и гражданству; персональные данные (152-ФЗ); прогноз раз в семестр, жёстких требований ко времени ответа нет

Для класса Dropout теоретический оптимальный порог откалиброванной модели $t^* = C_{FP} / (C_{FP} + C_{FN}) = 1 / 11 \approx 0{,}091$: из-за соотношения цен 10 : 1 направлять к куратору выгодно уже при вероятности отчисления около 9 %. Значения C_FN и C_FP условные; в реальном проекте их оценивают по стоимости обучения одного студента и часу работы куратора.

3. Данные и разведочный анализ

Набор собран в Политехническом институте Порталегре (Португалия) и описывает студентов, поступивших в 2008–2019 гг. на 17 программ бакалавриата. 4424 строки, 36 признаков и целевая переменная; все признаки числовые, категориальные закодированы целыми кодами.

– Пропусков и полных дубликатов нет.

– Баланс классов: Graduate — 2209 (49,9 %), Dropout — 1421 (32,1 %), Enrolled — 794 (17,9 %). Класс Enrolled самый малочисленный и наиболее трудный — он «промежуточный» между двумя другими.

– Девять номинальных признаков (семейное положение, способ поступления, программа, предыдущее образование, гражданство, образование и профессии родителей) имеют от 6 до 46 значений, большая часть которых редкие (< 1 %): например, у Nacionality редки 20 из 21 значений. Для логистической регрессии редкие категории объединены (OneHotEncoder с min_frequency = 0,01), бустинги работают с ними напрямую.

– Возраст при зачислении: медиана 20 лет, максимум 70; у отчисленных медиана 23 года против 19 у выпускников.

– Оплата обучения: при задолженности (Tuition fees up to date = 0, 528 студентов) отчисляются 86,6 %, при своевременной оплате — 24,7 %; у должников (Debtor = 1) доля отчисления 62 % против 28 %.

– Стипендиаты отчисляются в 3 раза реже (12,2 % против 38,7 %); мужчины — чаще женщин (45,1 % против 25,1 %).

– Медиана сданных дисциплин в 1-м семестре: Dropout — 2, Enrolled — 5, Graduate — 6.

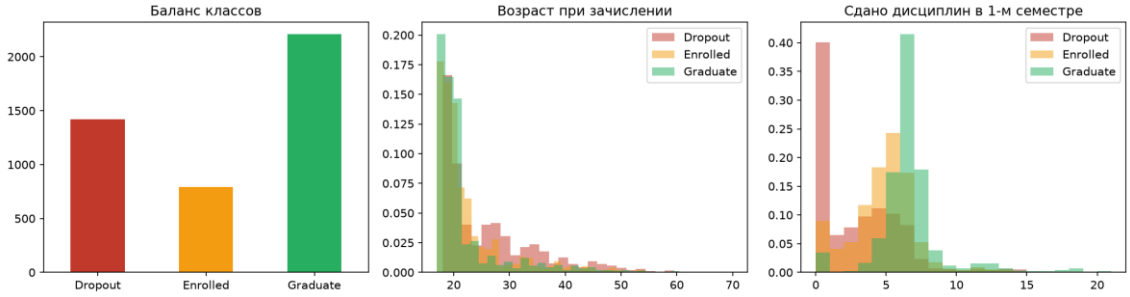


Рисунок 1 — Баланс классов и распределения признаков по классам

Поиск утечек

Каждый признак оценён по отдельности функцией leak_scan: ROC-AUC для бинарной цели «Dropout или нет»; номинальные признаки закодированы средним таргета (только для поиска утечек).

Таблица 2 — Признаки с наибольшим индивидуальным ROC-AUC

Признак	**ROC-AUC**	**Вердикт**
Curricular units 2nd sem (approved)	0,855	Исключён: успеваемость 2-го семестра неизвестна ни при зачислении, ни после 1-го семестра
Curricular units 1st sem (approved)	0,818	Только сценарий B: известен после 1-го семестра
Curricular units 2nd sem (grade)	0,814	Исключён (2-й семестр)
Curricular units 1st sem (grade)	0,773	Только сценарий B
Age at enrollment	0,671	Допустим
Application mode	0,670	Допустим
Course	0,657	Допустим
Tuition fees up to date	0,649	Только сценарий B: состояние оплаты фиксируется в ходе обучения
Scholarship holder	0,614	Допустим (назначается при зачислении)
Curricular units 2nd sem (enrolled)	0,611	Исключён (2-й семестр)
Curricular units 1st sem (enrolled)	0,606	Только сценарий B
Gender	0,604	Допустим, проверяется на справедливость

Явного дубликата ответа в наборе нет (максимум 0,855 < 0,9), но ловушка варианта — во времени появления признаков: успеваемость за семестры становится известна позже момента прогноза. Поэтому признаки 2-го семестра (6 столбцов) исключены из обоих сценариев, признаки 1-го семестра и оплаты

(8 столбцов) используются только в сценарии B. В сценарии A — 22 признака, в B — 30 исходных.

Контрольный прогон показывает цену утечки: логистическая регрессия с признаками 2-го семестра даёт Macro-F1 = 0,6988 на кросс-валидации против 0,6646 в честном сценарии B. Прирост выглядит умеренным, но в эксплуатации он недостижим: в конце 1-го семестра этих столбцов ещё не существует.

4. Методы

4.1. Схема валидации

Объекты независимы, классы несбалансированы, поэтому, как у авторов набора, используется стратифицированное разбиение: отложенная тестовая выборка 20 % (885 студентов, из них 284 Dropout), на обучающей части (3539 студентов) — StratifiedKFold с 5 фолдами. Тест не использовался до шага 6, порог и калибровка подбирались на out-of-fold прогнозах обучающей выборки.

Все преобразования признаков построчные и не используют статистик выборки, а масштабирование и кодирование для логистической регрессии находятся внутри пайплайна и обучаются только на обучающих фолдах. Функции признаков вынесены в модуль features.py — без него сохранённая модель не загрузится в другом процессе.

4.2. Baseline

Константная модель DummyClassifier(strategy = 'prior') всегда предсказывает Graduate и даёт Macro-F1 = 0,2220. Логистическая регрессия (стандартизация числовых признаков, one-hot для номинальных) даёт 0,5116 в сценарии A и 0,6646 в сценарии B.

4.3. Новые признаки и абляция

Таблица 3 — Новые признаки

Признак	Определение	Сценарий
approved_ratio_1	Доля сданных дисциплин 1-го семестра: approved / enrolled	B
pass_rate_eval_1	Доля успешных аттестаций: approved / evaluations	B
zero_approved_1	Записан на дисциплины, но не сдал ни одной	B
payment_problem	Есть задолженность: Debtor = 1 или Tuition fees up to date = 0	B
grade_x_ratio_1	Средний балл, взвешенный долей сданных дисциплин	B
mature_student	Возраст при зачислении 25 лет и старше	A, B
grade_gain	Разность конкурсного балла и балла предыдущего образования	A, B

Абляция выполнена на сценарии B с LightGBM по умолчанию; для снижения шума кросс-валидация повторена 3 раза с разными зёрнами (15 фолдов). Без новых признаков Macro-F1 = 0,6803 ± 0,0203, со всеми семью —

0,6811 ± 0,0195. Вклад признака — разность между полным набором и набором без этого признака.

Таблица 4 — Абляция новых признаков (сценарий B, Macro-F1)

Признак	**Macro-F1 без него**	**Вклад**	**Решение**
approved_ratio_1	0,6752	+0,0060	Оставить
pass_rate_eval_1	0,6791	+0,0021	Оставить
payment_problem	0,6803	+0,0009	Оставить
zero_approved_1	0,6808	+0,0004	Оставить
grade_x_ratio_1	0,6811	+0,0001	Оставить
mature_student	0,6822	-0,0011	Удалить
grade_gain	0,6866	-0,0055	Удалить

Пять признаков успеваемости и оплаты оставлены, два «анкетных» (mature_student, grade_gain) удалены: возраст уже есть в исходных данных, а разность баллов добавляет шум. Наибольший вклад у доли сданных дисциплин (+0,006). При этом разброс по фолдам (±0,02) больше любого отдельного вклада, поэтому корректная формулировка — «влияние новых признаков в пределах шума», а не «признаки значимо улучшили модель». Итог: 22 признака в сценарии A и 35 в сценарии B.

4.4. Модели и подбор гиперпараметров

LightGBM: подбор гиперпараметров Optuna (TPE, 50 испытаний на каждый сценарий, целевая функция — средний Macro-F1 по 5 фолдам). CatBoost: обучение с ранней остановкой (200 итераций без улучшения, метрика TotalF1 macro) на 20 % обучающей выборки, затем 5-fold CV с найденным числом итераций (587 для B и 954 для A). Каждый эксперимент записан в experiments.csv (120 записей).

Таблица 5 — Пространство поиска и лучшие гиперпараметры LightGBM (сценарий B)

Параметр	**Диапазон поиска**	**Лучшее значение**
n_estimators	100–1000, шаг 100	200
learning_rate	0,005–0,2 (лог.)	0,0373
num_leaves	7–128 (лог.)	101
min_child_samples	5–200 (лог.)	99
subsample	0,5–1,0	0,975
colsample_bytree	0,3–1,0	0,435
reg_lambda	0,001–10 (лог.)	0,0025
class_weight	None, balanced	balanced

Лучшая конфигурация — 200 деревьев по 101 листу, но с крупным минимальным размером листа (99) и случайным выбором 43 % признаков на дерево; веса классов balanced усиливают редкий класс Enrolled, что прямо

повышает Macro-F1. Поскольку веса искажают вероятности, калибровка на шаге 7 обязательна.

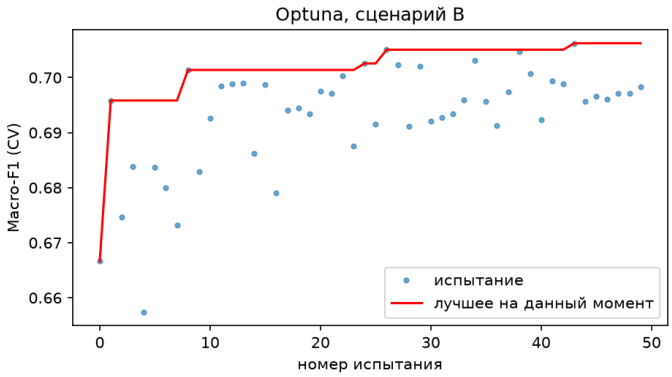


Рисунок 2 — Ход подбора гиперпараметров Optuna (сценарий B)

5. Результаты

5.1. Сравнение моделей

Таблица 6 — Качество моделей: кросс-валидация (5 фолдов) и отложенный тест (885 студентов)

Сц.	Модель	Macro-F1 CV	Macro-F1 тест	ROC-AUC Dropout тест
A	Константа	0,2220 ± 0,000	0,2221	0,5000
A	Логистическая регрессия	0,5116 ± 0,011	0,4837	0,7711
A	CatBoost	0,5112 ± 0,008	0,4840	0,7728
A	LightGBM после подбора	0,5578 ± 0,017	0,5396	0,7701
B	Константа	0,2220 ± 0,000	0,2221	0,5000
B	Логистическая регрессия	0,6660 ± 0,019	0,6770	0,9024
B	CatBoost	0,6657 ± 0,015	0,6538	0,9032
B	LightGBM после подбора	0,7062 ± 0,013	0,6630	0,8945

Таблица 7 — 95-процентные бутстреп-интервалы Macro-F1 на тесте (1000 выборок)

Сравнение A − B	ДИ модели A	ДИ разности	Значимо
LightGBM B − логистическая регрессия B	[0,627; 0,695]	[-0,045; +0,018]	нет
LightGBM B − CatBoost B	[0,627; 0,695]	[-0,022; +0,042]	нет
LightGBM B − LightGBM A (ценность 1-го семестра)	[0,627; 0,695]	[+0,087; +0,159]	да
LightGBM B − константа	[0,627; 0,695]	[+0,403; +0,475]	да
LightGBM A − логистическая регрессия A	[0,506; 0,573]	[+0,025; +0,089]	да

Лучшая по кросс-валидации модель — LightGBM после подбора (сценарий B, 0,7062); она и оценена на тесте один раз: Macro-F1 = 0,6630, 95 % ДИ [0,627; 0,695].

Главное наблюдение — честный отрицательный результат. На кросс-валидации подобранный LightGBM опережал логистическую регрессию на 0,04, но на тесте разница с ней составила −0,011, и интервал разности [−0,045; +0,018] содержит 0. Превосходство бустинга над линейным baseline по Macro-F1 не подтверждено. Причины: (1) оптимистичное смещение — выбран лучший

из 50 конфигураций по тем же фолдам, и часть выигрыша — подгонка под шум (разброс ±0,013); (2) зависимость отчисления от успеваемости и оплаты почти монотонна, и линейная модель её хорошо описывает; (3) тест мал — 885 строк, ширина интервала около 0,07. Выбор модели не пересматривался по тесту, иначе тест превратился бы в валидацию.

Значимо подтверждены два вывода: модель B лучше константы на +0,40…+0,48, а модель «после 1-го семестра» лучше модели «при зачислении» на +0,09…+0,16 Macro-F1 — данные первого семестра несут основную информацию о риске. В сценарии A LightGBM значимо лучше и логистической регрессии, и CatBoost.

Таблица 8 — Качество по классам на тесте (LightGBM, сценарий B, argmax)

Класс	**Precision**	**Recall**	**F1**	**Объектов**
Dropout	0,780	0,676	0,725	284
Enrolled	0,391	0,541	0,454	159
Graduate	0,833	0,790	0,811	442

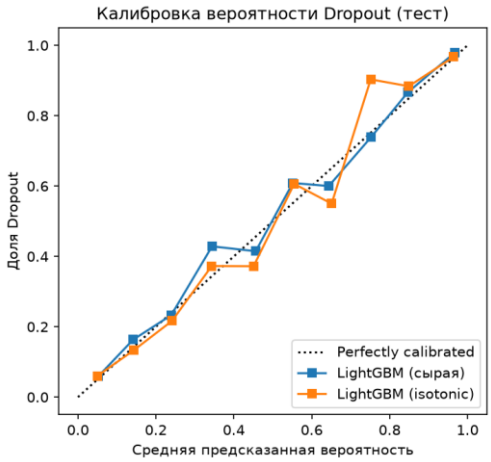
Ошибки модели сосредоточены в классе Enrolled (F1 = 0,454): «ещё учащийся» студент по успеваемости похож либо на выпускника, либо на отчисленного — его судьба решится позже горизонта данных. Для бизнес-задачи важен класс Dropout: F1 = 0,725, ROC-AUC = 0,895.

5.2. Калибровка

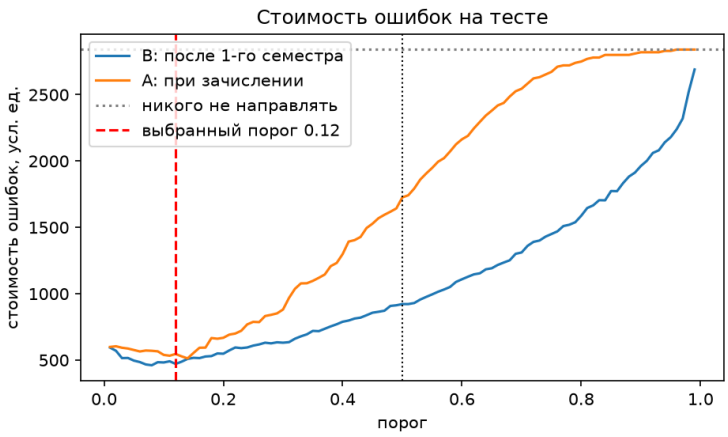
Brier score вероятности Dropout на out-of-fold прогнозах: сырая модель 0,1021, sigmoid 0,1026, isotonic 0,1024. Выбрана изотонная калибровка (положительных объектов много — 1137 в обучении). На тесте Brier уменьшился с 0,1121 до 0,1099, ROC-AUC почти не изменился (0,8945 → 0,8957): калибровка исправляет уровень вероятностей, а не порядок. Несмотря на веса классов, вероятность Dropout у сырой модели уже близка к диагонали, поэтому выигрыш от калибровки небольшой; основные отклонения — в редко заполненных интервалах 0,6–0,8 (рисунок 3, а).

5.3. Выбор порога и стоимость ошибок

Порог подобран перебором от 0,01 до 0,99 на out-of-fold калиброванных прогнозах обучающей выборки по минимуму суммарной стоимости: t = 0,12; теоретический t* = 1/11 = 0,091, Близость двух значений подтверждает, что модель откалибрована; небольшое смещение вверх объясняется пологим минимумом кривой стоимости и дискретностью изотонной калибровки, Для сценария A найденный порог — 0,08.



а) калибровочная кривая



б) стоимость ошибок от порога

Рисунок 3 — Калибровка вероятности Dropout и суммарная стоимость ошибок на тестовой выборке

Таблица 9 — Сравнение стратегий на тесте (284 отчисления из 885 студентов)

Стратегия	**TP**	**FP**	**FN**	**Precision**	**Recall**	**Направлено**	**Стоимость**
Никого не направлять	0	0	284	—	0,000	0,0 %	2840
Направлять всех	284	601	0	0,321	1,000	100,0 %	601
B: argmax по 3 классам	192	54	92	0,780	0,676	27,8 %	974
B: порог 0,50	196	42	88	0,824	0,690	26,9 %	922
B: порог 0,12 (по стоимости)	260	231	24	0,529	0,915	55,5 %	471
A: порог 0,08 (при зачислении)	279	520	5	0,349	0,982	90,3 %	570

Стратегия «никого не направлять» стоит 2840 усл. ед. Выбранный порог 0,12 снижает потери до 471 (на 83 %), находя 91,5 % будущих отчислений при precision 0,53. Порог 0,5 и решение «по наибольшей вероятности» вдвое хуже (922 и 974): из-за цены 10 : 1 пропуск обходится дороже десяти лишних консультаций. Модель «при зачислении» (570) уступает модели B на 99 единиц и отбирает 90 % студентов — это почти «направлять всех» (601).

Важное ограничение: оптимальный порог направляет к куратору 55 % студентов. Если кураторов меньше, порог следует поднять до уровня пропускной способности: например, порог 0,5 отбирает 27 % студентов с precision 0,82 и всё равно сокращает потери втрое относительно бездействия.

6. Интерпретация модели (SHAP)

Вклады признаков посчитаны точным TreeSHAP для класса Dropout на всех 885 студентах тестовой выборки, в логитах. По горизонтали — вклад: вправо — в сторону отчисления; цвет — значение признака (красный — высокое, синий — низкое).

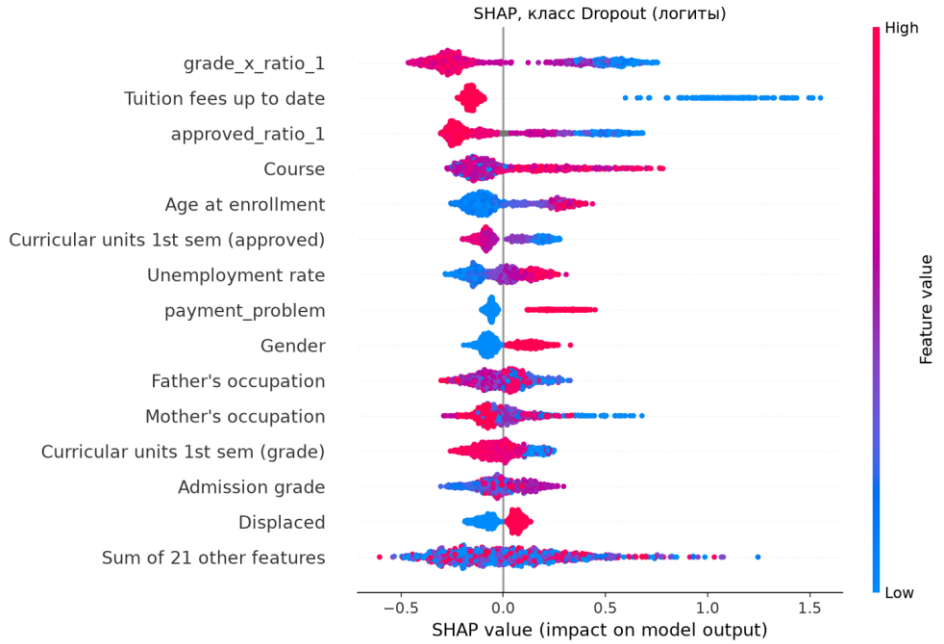


Рисунок 4 — Вклады признаков в вероятность отчисления (SHAP, тест, логиты)

Наблюдения по графику:

– **Успеваемость 1-го семестра** — главный сигнал: низкие значения взвешенного балла (grade_x_ratio_1) и доли сданных дисциплин (approved_ratio_1) сдвигают прогноз к отчислению до +0,75 логита. Три из пяти новых признаков попали в первую десятку.

– **Задолженность по оплате** (Tuition fees up to date = 0) даёт самый сильный единичный вклад — до +1,5 логита; своевременная оплата снижает риск. Это согласуется с EDA: 87 % должников отчисляются.

– **Программа обучения (Course)** и **возраст** — следующие по важности: студенты старшего возраста рискуют больше (совмещение с работой, семьёй).

– **Безработица** в год поступления и признак Displaced вносят небольшой вклад — модель частично запоминает когорту поступления; это нужно контролировать при переобучении.

– **Пол (Gender)** входит в первую десятку: мужской пол сдвигает прогноз к отчислению. Это требует проверки на справедливость (раздел 7).

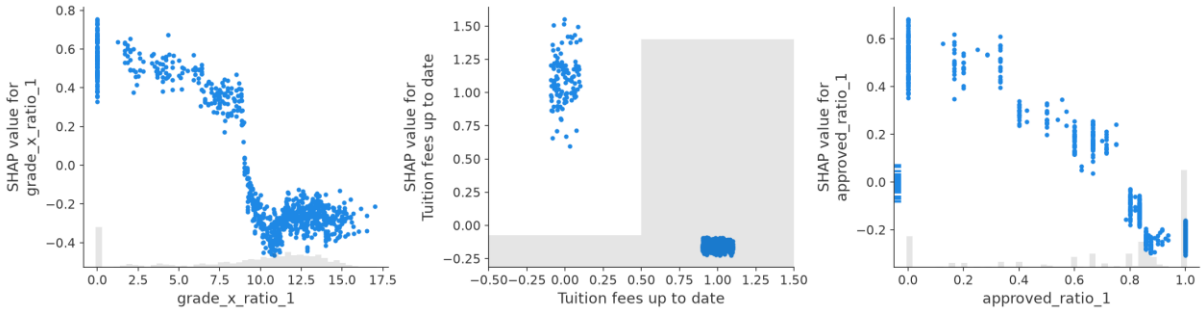
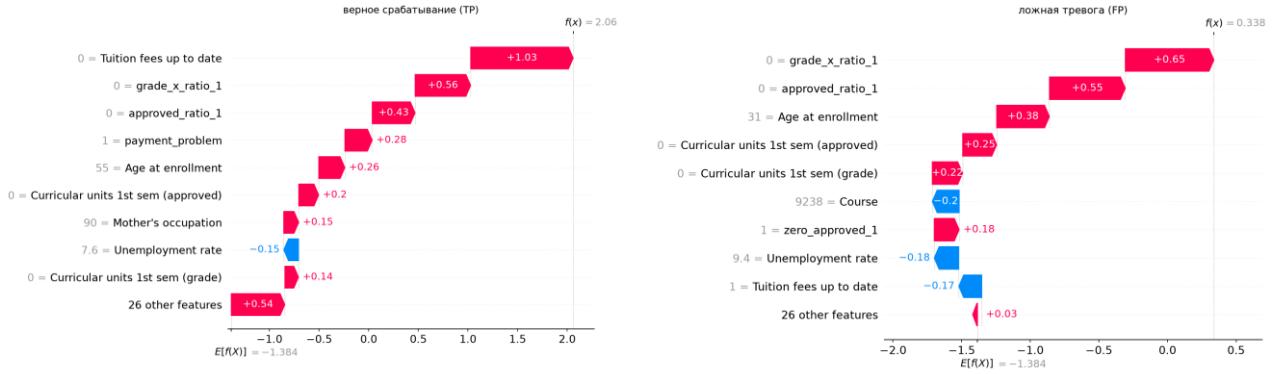


Рисунок 5 — Зависимость вклада от значения для трёх ключевых признаков

Графики зависимости показывают пороговое поведение: вклад взвешенного балла резко падает около 9–10 баллов (при 20-балльной шкале), доля сданных дисциплин снижает риск почти линейно от 0 до 0,8, а у задолженности по оплате два чётких уровня: около +1,1 логита при долге и −0,15 без долга.

Разбор отдельных прогнозов (waterfall) для трёх студентов тестовой выборки:



а) верное срабатывание (TP), p = 1,000, факт — Dropout

б) ложная тревога (FP), p = 0,940, факт — Enrolled

Рисунок 6 — Разбор прогнозов: верное срабатывание и ложная тревога (SHAP waterfall, логиты)

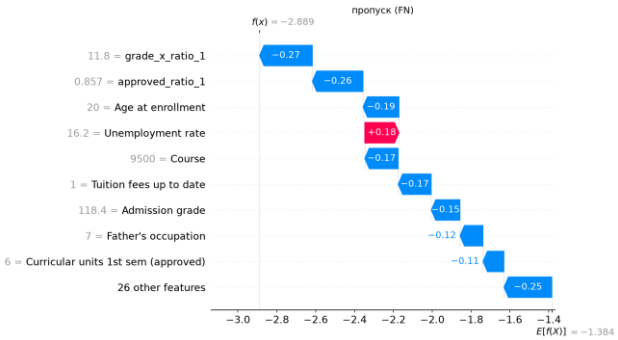


Рисунок 7 — Разбор прогноза: пропуск (FN), p = 0,019, факт — Dropout

Верное срабатывание: студенту 55 лет, обучение не оплачено, в 1-м семестре не сдано ни одной дисциплины — все основные вклады однонаправленны, сильнейший — долг по оплате (+1,03 логита). Ложная тревога (p = 0,94, на деле Enrolled): студент 31 года не сдал ни одной дисциплины в 1-м семестре, хотя обучение оплачено; модель по успеваемости относит его к отчисляемым, а он продолжает учиться — вероятно, с повторным прохождением курса. Для куратора это всё равно студент группы риска, и консультация оправдана. Пропуск (p = 0,019): студент сдал 6 из 7 дисциплин со средним баллом около 13,8, оплачивает обучение, ему 20 лет — по данным 1-го семестра признаков риска нет; отчисление вызвано событиями после первого

семестра, которых в модели нет. Такие ошибки устраняются только повторным прогнозом после 2-го семестра.

Таблица 10 — Важность признаков: SHAP против прироста (gain)

Признак	**Ср. |SHAP| Dropout**	**Ранг SHAP Dropout**	**Ранг SHAP (3 класса)**	**Ранг gain**
grade_x_ratio_1	0,344	1	2	1
Tuition fees up to date	0,273	2	4	5
approved_ratio_1	0,252	3	1	2
Course	0,171	4	3	4
Age at enrollment	0,150	5	6	9
Curricular units 1st sem (approved)	0,115	6	12	8
Unemployment rate	0,109	7	13	16
payment_problem	0,101	8	11	15
Gender	0,095	9	17	23
Father's occupation	0,094	10	9	13

Первые четыре признака совпадают по обоим методам с точностью до перестановки, дальше порядок расходится: безработица по SHAP седьмая, по gain — шестнадцатая; пол — девятый против двадцать третьего. Причины две. Во-первых, gain суммируется по деревьям всех трёх классов, а SHAP здесь посчитан только для Dropout — пол и безработица важны именно для отличия отчисления от остальных исходов. Во-вторых, gain завышает непрерывные признаки с множеством точек разреза (средний балл 1-го семестра шестой по gain и двенадцатый по SHAP), а SHAP измеряет фактическое влияние на прогнозы. Кроме того, сильно связанные признаки успеваемости делят вклад между собой, и важность каждого по отдельности занижена.

7. Дополнительное задание: справедливость модели

Чувствительные признаки — пол, возраст и гражданство. При выбранном пороге 0,12 на тесте сравнивались доля направленных к куратору и recall по группам.

Таблица 11 — Решения модели по группам (тест, порог 0,12)

Группа	**n**	**Доля Dropout**	**Направлено**	**Recall**	**Precision**
Женщины	570	0,244	0,470	0,885	0,459
Мужчины	315	0,460	0,708	0,945	0,614
Возраст ≤ 20	490	0,218	0,451	0,888	0,430
Возраст 21–25	180	0,322	0,600	0,914	0,491
Возраст > 25	215	0,553	0,753	0,941	0,691
Граждане	861	0,319	0,553	0,916	0,529
Иностранцы	24	0,375	0,625	0,889	0,533

Доля направленных различается сильно (47 % женщин против 71 % мужчин), но это в основном отражает разную долю отчислений в группах (24 % против 46 %). Более важная для справедливости метрика — recall (равенство

возможностей): у женщин и младших студентов он ниже на 5–6 п. п. (0,885 против 0,945), то есть отчисляющиеся женщины и вчерашние школьники немного чаще остаются без помощи. Группа иностранцев слишком мала (24 человека) для выводов.

Мера коррекции — модель без чувствительных признаков (пол, возраст, гражданство, страна): Macro-F1 на кросс-валидации 0,6995 против 0,7062, ROC-AUC Dropout на тесте 0,890 против 0,896, стоимость ошибок 508 против 471 (+8 %). Recall выравнивается и растёт во всех группах: женщины 0,935, мужчины 0,959, возраст ≤ 20 — 0,935, > 25 — 0,975, хотя направляется больше студентов (порог снизился до 0,07). Рекомендация: в эксплуатации использовать модель без чувствительных признаков — потеря качества мала (в пределах разброса по фолдам), а решение «направить к куратору» не зависит напрямую от пола и возраста. Полностью влияние не исчезает, так как часть информации о возрасте и поле несут косвенные признаки (способ поступления, семейное положение), поэтому recall по группам нужно отслеживать регулярно.

8. Сохранение модели

Финальный пайплайн «features.prepare → CalibratedClassifierCV(LightGBM, isotonic, cv = 5)» обучен на всей обучающей выборке и сохранён в model.joblib вместе с порогом 0,12, списком классов, сценарием и перечнем входных столбцов. Сохранена именно откалиброванная модель, так как порог подбирался для калиброванных вероятностей. Файл input_schema.json описывает 30 входных признаков: для числовых — диапазон, для номинальных — допустимые коды. Проверка пройдена: загруженная модель даёт те же прогнозы (np.allclose), стоимость ошибок на тесте после загрузки — те же 471. Размер model.joblib — 7,0 МБ, в experiments.csv — 120 записей.

Таблица 12 — Артефакты работы

Файл	**Содержание**
lab1_Klonin.ipynb	Весь код, выполняется в Google Colab сверху вниз
features.py	Функции признаков (создаётся ноутбуком, нужен для загрузки модели)
model.joblib	Откалиброванный пайплайн LightGBM и порог 0,12
input_schema.json	Описание 30 входных признаков
experiments.csv	Журнал 120 экспериментов

9. Выводы

– **Риск отчисления хорошо предсказуем после первого семестра.** Среди студентов, которых модель отмечает как группу риска при пороге 0,5, отчисляются 82 %, тогда как в среднем — 32 %. При поступлении риск прогнозируется заметно хуже: анкетных данных недостаточно, решающую информацию даёт первая сессия.

– **Две главные причины риска — долги по оплате и несданные дисциплины.** Из студентов с неоплаченным обучением отчисляются 87 %. Напоминание об оплате и рассрочка, а также пересдачи и консультации по проваленным предметам сразу после первой сессии — самые прямые рычаги удержания.

– **Направлять к куратору выгодно с большим запасом.** Если пропущенное отчисление в 10 раз дороже консультации, направление всех студентов с вероятностью отчисления выше 12 % сокращает потери на 83 % и охватывает 9 из 10 будущих отчисленных. При ограниченном числе кураторов можно отбирать только 27 % самых рискованных студентов — потери всё равно снизятся втрое.

– **Модель не должна решать по полу и возрасту.** Рекомендуется версия без этих признаков: она почти не уступает в качестве и одинаково хорошо находит студентов группы риска среди мужчин и женщин, молодых и взрослых.

– **Часть отчислений модель не увидит.** Студенты, успешно закрывшие первую сессию, но ушедшие позже, по данным первого семестра неотличимы от остальных. Нужен повторный прогноз после второго семестра и переобучение модели на новых наборах студентов не реже раза в год.

Ограничения: денежные оценки условны и опираются на соотношение C_FN : C_FP = 10 : 1; эффект посчитан на исторических данных и предполагает, что консультация предотвращает отчисление, чего эксперимент не проверял. Достоверную оценку даст только пилот с контрольной группой. Данные получены в одном португальском вузе, и перенос модели в другой вуз требует переобучения.

Приложения

Источники данных. Realinho V., Machado J., Baptista L., Martins M. V. Predicting Student Dropout and Academic Success // Data. 2022. Vol. 7, № 11. P. 146. Набор UCI Machine Learning Repository, id = 697.

Репозиторий с кодом и артефактами работы: https://github.com/Twins-s/lab1-applied-ai